Phenomenon Study 方案：验证“对所有样本做线搜索式困难样本挖掘/生成”的必要性

0. 这套 study 想证明什么

这篇论文的核心叙事不是“当前 hardest 的样本最重要”，而是：

- 传统困难样本挖掘往往只盯住**损失大的少数样本对**；
- 这样会忽略大量“容易样本”中携带的**全局结构信息**；
- 困难样本生成的意义，是把这些容易样本也变成“有训练价值的困难样本”，从而更完整地刻画嵌入空间结构。:contentReference[oaicite:0]{index=0}

所以，现象研究不应该去证明“所有样本本身都难”，而应该去证明：

> **如果只对当前已经很难的样本做线搜索式 hard mining，会导致边界监督覆盖不足；而如果让所有样本都作为 anchor 参与一次几何约束的线搜索/生成，就能更完整地覆盖类边界，从而更好地强化边界。**

---

1. 实验情境设计

1.1 数据情境：边界困难主导，而不是全局噪声主导

构造一个**双视图、三簇**的 synthetic 数据集，底层语义空间使用 **Student-t 分布** 而不是高斯：

- 3 个簇中心：`(-2,0)`，`(2,0)`，`(0,2.8)`
- 每类 300~500 个样本
- 使用 `df=4` 或 `df=5` 的二维 Student-t 分布采样
  这样簇有重尾，天然会出现：
  - 核心 easy 样本
  - 类尾部样本
  - 边界附近样本
  - 少量伪困难样本

View 1

对底层语义空间做线性变换 + 小噪声。

View 2

也做线性/弱非线性变换，但**只在边界带附近**加入定向扰动，让部分边界样本在 view 2 中更偏向竞争簇。

这样可得到 4 类 oracle 样本：

- **A: easy-consistent**
  远离边界，跨视图一致
- **B: boundary-consistent**
  靠近边界，但跨视图仍一致
- **C: boundary-conflict**
  靠近边界，跨视图存在冲突
- **D: pseudo-hard**
  由重尾或单视图扰动导致的伪困难样本

1.2 方法对比：必须控制“总 hard loss 强度”

为了证明“所有样本都做线搜索”的必要性，不能只比较“生成样本更多”的版本。
必须在**总 hard loss 权重一致**的前提下比较。

设计 3 组模型：

M0. Baseline

不加困难样本挖掘/生成。

M1. Hard-only Line Search

只对**当前低 margin / 高 loss 的那部分样本**做线搜索式困难样本生成。
也就是常见的“只对 hardest anchors 做挖掘”。

M2. All-anchor Line Search

对**所有样本都允许作为 anchor** 做一次线搜索式困难样本生成；
但 hard loss 对生成样本数做平均或归一化，确保总训练强度与 M1 可比。

> 重点不是让 M2 有更多样本，而是让 M2 的 **anchor 覆盖更广**。

1.3 线搜索方式（贴近论文思路）

为了贴近这篇论文，可采用“代数式/几何式”的困难样本构造，而不是 GAN/VAE。

你可以做一版简化的线搜索生成：

- 给定锚点 `z_i`
- 定义其正类中心 `c_pos` 和竞争/异类中心 `c_neg`
- 沿某个几何方向做线搜索，构造：
  - hard positive
  - hard negative

这里不必在 phenomenon study 中争论“中心线”还是“竞争原型线”哪个最终更优；
因为当前要证明的是：

> **是否有必要让所有样本都参与几何式 hard sample generation，而不是只对 hardest 子集做。**

1.4 一个关键干预：anchor 来源分桶实验

为了更直接地证明“所有样本都做 line search”是有必要的，建议把 anchor 分成三桶：

- **E 桶**：easy / high-margin anchors
- **M 桶**：medium-margin anchors
- **H 桶**：hard / low-margin anchors

然后做 4 种策略：

1. **Only-H**：只对 H 桶做线搜索
2. **M+H**：对中难样本做线搜索
3. **All (E+M+H)**：所有样本都做线搜索
4. **Random anchors**：随机同数量 anchors 做线搜索（作为负对照）

这样你就能证明：

- 不是“只要 hard anchor 就够”
- 不是“随便多找点 anchor 都行”
- 而是“**让 easy/core 样本也贡献几何外延出来的 hard samples**”有额外价值

这正是论文想讲但没被严格验证的点。:contentReference[oaicite:1]{index=1}

---

2. 需要看的实验指标

2.1 全局聚类指标

这些不是重点，但要记录：

- ACC
- NMI
- ARI

作用：说明方法没有破坏整体结构。

2.2 边界区域指标（重点）

只在 oracle 边界带（B+C）上计算：

- **Boundary-ACC**
- **Boundary-NMI**
- **Boundary-ARI**

这是最关键的一组指标。
因为“困难样本生成”如果真有意义，应该首先改善边界区，而不是核心区。

2.3 边界区 margin 指标

定义聚类 margin：

[
m*i* = *q*{i,(1)} - q_{i,(2)}
]

记录：

- 全体样本平均 margin
- 边界样本平均 margin
- B 组 margin
- C 组 margin

如果方法有效，应看到：

- 边界区域的 margin 上升更明显

2.4 跨视图 disagreement 指标

对于双视图，可定义：

[
d_i = JS(q_i^1, q_i^2)
]

记录：

- 全体 disagreement
- 边界样本 disagreement
- C 组 disagreement

如果方法有效，应看到：

- **boundary-conflict 样本的 disagreement 下降**
- 而不仅仅是全局平均变化很小

2.5 最关键的“覆盖率”指标

这组指标是为了专门证明 **为什么所有样本都要做 line search**。

(a) **类别覆盖率**（Class Coverage）

生成的 hard samples 是否覆盖到更多类/更多 prototype pair。

例如：

$$
\text{Coverage}_{class} = \frac{\#\{\text{至少产生过 hard sample 的类}\}}{K}
$$

(b) **竞争边界覆盖率**（Boundary-Pair Coverage）

统计 hard samples 覆盖了多少组竞争簇对。

例如：

$$
\text{Coverage}_{pair} = \frac{\#\{(c_a,c_b)\ \text{被 hard samples 覆盖}\}}{\#\{\text{所有有效竞争簇对}\}}
$$

(c) **径向覆盖率**（Radial Coverage）

在每个类内部，统计被选中/生成的样本来自：

- 核心区域
- 中间区域
- 尾部区域

如果只对 hardest anchors 做线搜索，通常会高度集中在“已经模糊的局部带”；
而 All-anchor 版本会覆盖更多类尾部/类肩部结构。
💬
这组指标是**整套 phenomenon study 的灵魂**。

2.6 训练过程指标（可选但推荐）

因为论文还强调了“对整体分布考虑更充分，训练更快/更稳定”的故事。:contentReference[oaicite:2]{index=2}

建议额外记录：

- 训练 loss 曲线
- prototype drift
- assignment flip rate

如果 All-anchor line search 真能提供更完整结构信息，理想情况下会看到：

- 收敛更平滑
- prototype 漂移更小
- 边界样本 assignment 翻转更少

---

3. 必做散点图

图名建议

Latent Scatter with Generated Hard Samples under Different Anchor Policies

画法

建议一张图做成 **3 个子图**：

- (a) Only-H
- (b) M+H
- (c) All (E+M+H)

每个子图都画：

- 灰色：所有样本
- 红色：oracle boundary samples (B+C)
- 蓝圈：被选中/生成的 hard samples

- 星号：prototype

这张图要看的不是“谁更集中在边界”

而是：

> **谁覆盖得更完整**

理想现象应是：

- **Only-H**：蓝圈高度堆在一小段最模糊区域
- **M+H**：覆盖更广，但仍偏局部
- **All**：蓝圈不仅覆盖最难边界，还覆盖各类外围/肩部区域，从而形成更完整的“边界壳层”

这张图一旦出来，你就能把“所有样本做 line search 的必要性”包装成：

> **不是因为所有样本都难，而是因为所有样本都能贡献“边界外延信息”。**

---

4. 理想中的实验现象

现象 1：Only-H 的 hard samples 很“准”，但覆盖很窄

表现为：

- Precision 很高
- 但 class coverage / pair coverage 很低
- 散点图中蓝圈挤在少数局部边界区
- boundary-ARI 改善有限

这说明：

> 只对 hardest anchors 做线搜索，只能强化局部最难点，无法补全整体边界结构。

现象 2：All-anchor 的边界覆盖最完整

表现为：

- 覆盖更多类
- 覆盖更多竞争簇对
- 覆盖更多类肩部/尾部区域
- 散点图上生成样本形成“更完整的边界带”

这支持：

> easy/core 样本虽然本身不难，但以它们为 anchor 经过线搜索生成后，仍能提供有价值的边界监督。

现象 3：All-anchor 在边界指标上优于 Only-H

表现为：

- 全局 ACC/NMI/ARI 差异可能不大
- 但 **Boundary-ARI / Boundary-NMI / Boundary margin** 明显更好
- C 组 disagreement 降幅更大

这说明：

> 所有样本参与 line search 的收益，不在于“更多 hard points”，而在于“更完整地塑造边界”。

现象 4：Random anchors 不如 All-anchor

如果 Random 和 All-anchor 生成样本数量一样，但：

- All-anchor 的边界指标更好
- 覆盖更有结构
- 收敛更稳定

那你就可以排除一种质疑：

> 不是“随便多搞点生成样本就行”，而是“按类结构/几何关系让所有样本参与一次 line search”才有意义。

现象 5：去掉 easy anchors，会损失一部分边界质量

如果你把 All-anchor 改成：

- 去掉 E 桶，只保留 M+H

然后发现：

- 覆盖下降
- 边界指标也下降

那么这就是最直接的证据：

> **easy samples 虽然本身不是 hardest，但它们作为 anchor 生成出来的样本，对完整边界建模是必要的。**

这正是对论文叙事最好的“反包装”。

---

5. 最终想得到的结论

如果理想现象成立，你最终可以把结论写成：

> 仅对当前 already-hard 样本做线搜索式困难挖掘，会导致生成监督集中在少数局部模糊区域，从而难以完整刻画类间边界。相比之下，让所有样本都参与一次几何约束的 line-search hard sample generation，虽然并不意味着所有样本本身都困难，但能够显著提升边界覆盖率，从而改善边界区域的聚类质量与跨视图一致性。

---

6. 一句话版 study 逻辑

这套 phenomenon study 不是为了证明：

> “所有样本都难”

而是为了证明：

> **“所有样本都可以贡献边界外延信息；如果只对 hardest 子集做 line search，会导致边界监督不完整。”**